智能系统安全实践：CNN与对抗样本

复旦白泽智能

系统软件与安全实验室

大纲

- 理解卷积神经网络（CNN）
- 卷积和池化操作
- 经典LeNet5模型

- 理解对抗样本的建模
- 问题形式化
- FGSM的解法

回顾：多层感知机（MLP）

■ 模型定义

- $h = \sigma(W_h x + b_h)$
- $o = W_o h + b_o$

■其中 $\sigma(h) = \frac{1}{1+e^{-h}}$

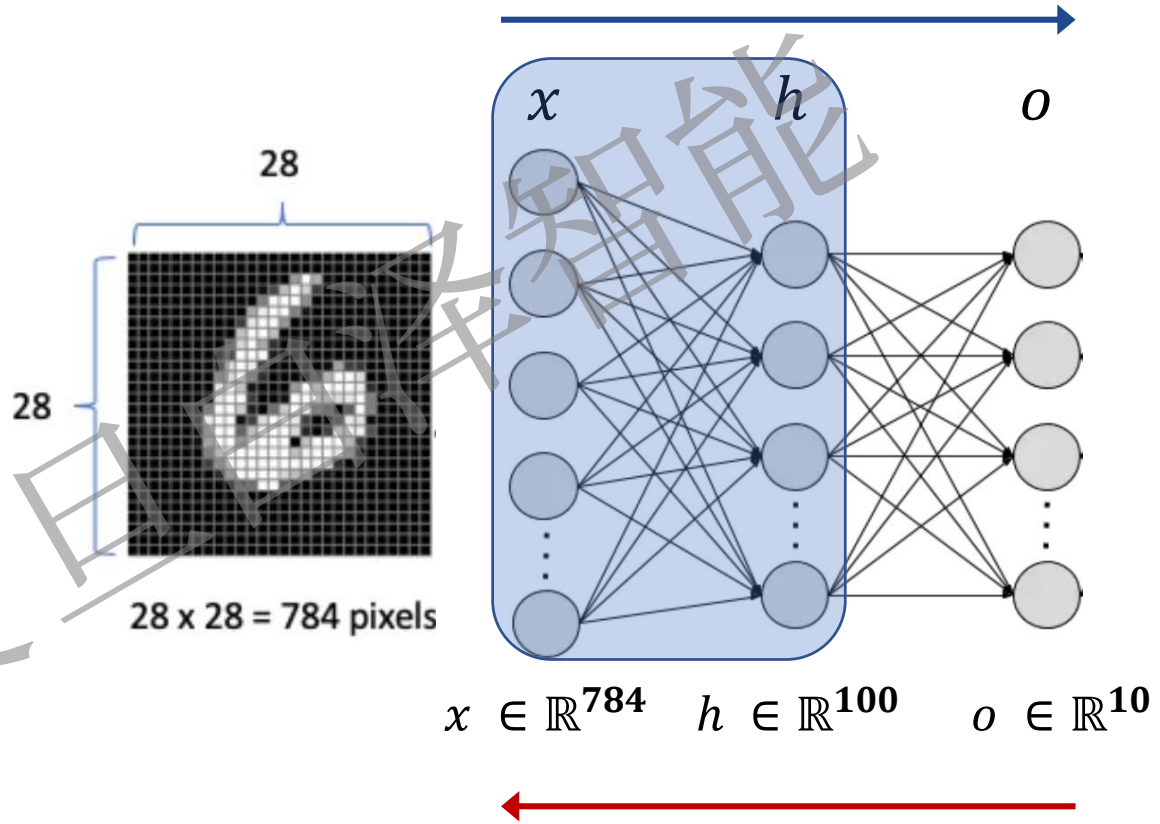

这里$W_h \in \mathbb{R}^{784\times100}$

卷积操作

- 卷积（Convolution）
  - 局部特征提取：
    - 不同于线性层的全局特征提取
    - 能捕获更细粒度的图像局部特征（边缘、纹理等）
  - 各个局部位置进行相同操作：
    - 滑动窗口
    - 参数共享 -> 减少参数量
  - 每个局部如何操作？
    - 逐元素相乘、相加
    - 本质上仍是$\boldsymbol{y} = \boldsymbol{W}\boldsymbol{x} + b$

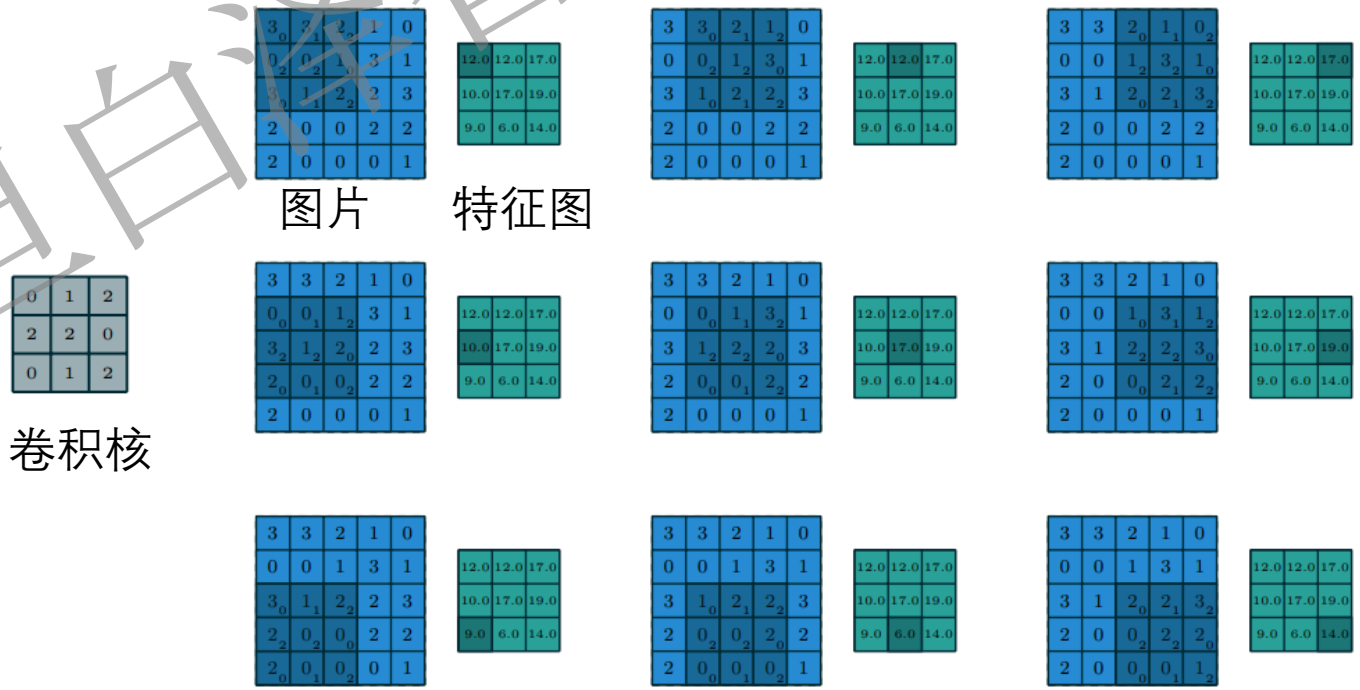

卷积的关键参数

- kernel_size：卷积核大小
- stride：滑动步长
- padding：两侧填充数目

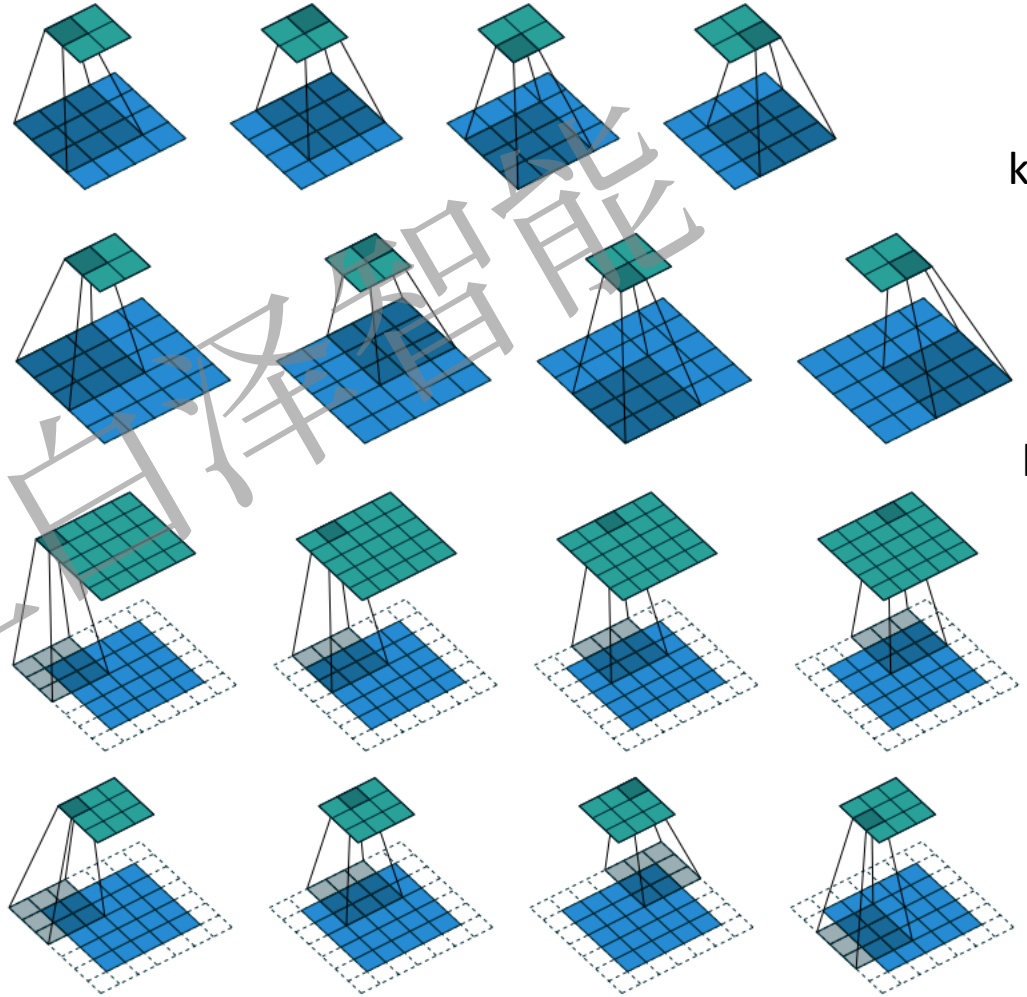

k=3, s=1, p=0

k=3, s=2, p=0

k=3, s=1, p=1

k=3, s=2, p=1

更多可视化资源：

https://github.com/vdumoulin/conv_arithmetic/blob/master/README.md （有动图！）

https://arxiv.org/pdf/1603.07285.pdf

卷积的关键参数

- 下面这个卷积操作，各个参数应该是多少呢?

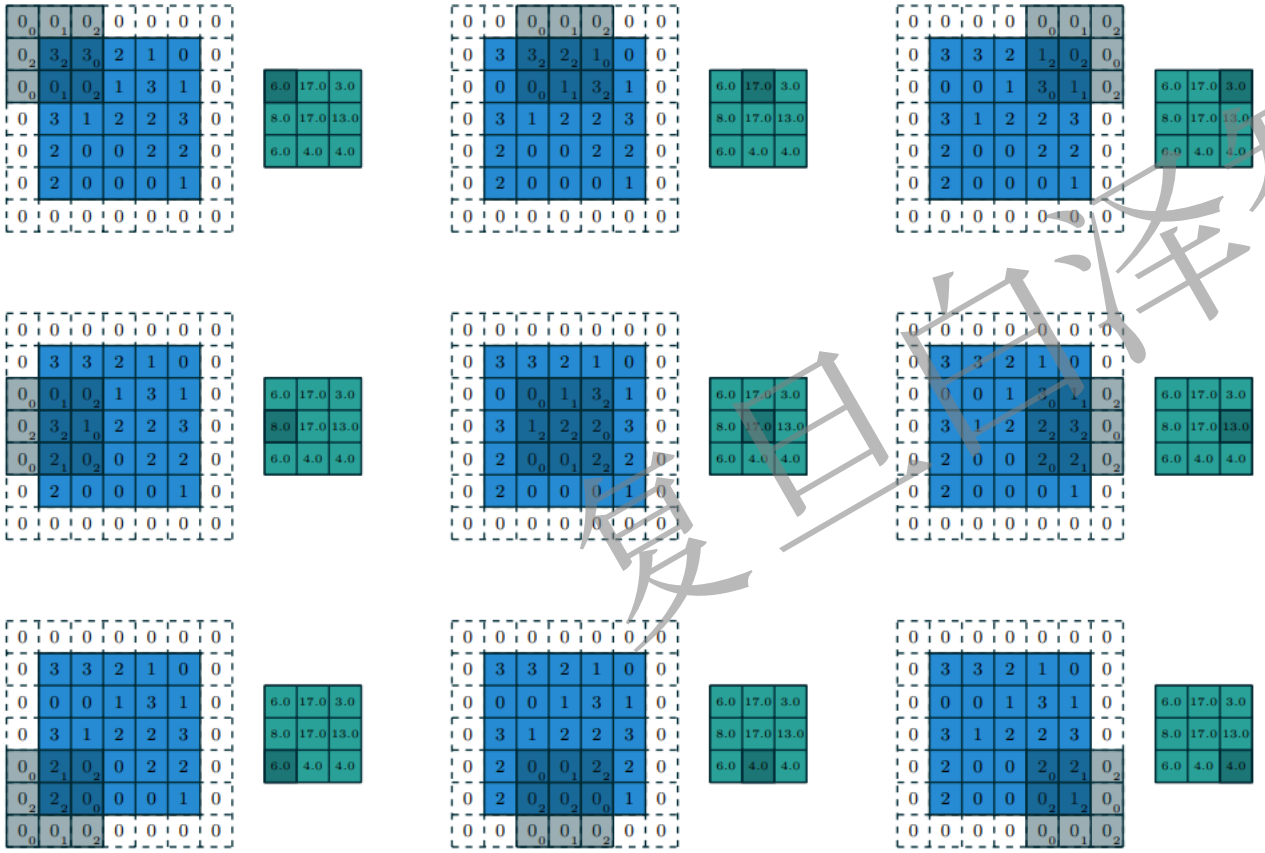

kernel_size = 3
stride = 2
padding = 1

CNN中的卷积

- 之前我们学习的卷积，输入都是单通道，输出也是单通道
- 在实际CNN中，每个卷积层
  - 输入有多个通道（例如，许多图片便是RGB三通道的）
  - 输出也有多个通道

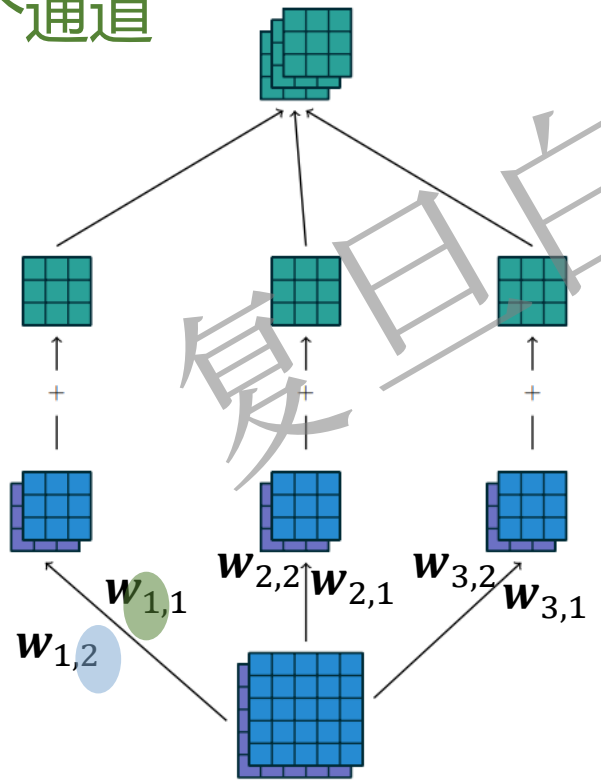

In the simplest case, the output value of the layer with input size (N, C_{in}, H, W) and output $(N, C_{\text{out}}, H_{\text{out}}, W_{\text{out}})$ can be precisely described as:

$$\text{out}(N_i, C_{\text{out}_j}) = \text{bias}(C_{\text{out}_j}) + \sum_{k=0}^{C_{\text{in}}-1} \text{weight}(C_{\text{out}_j}, k) \star \text{input}(N_i, k)$$

where $\star$ is the valid 2D cross-correlation operator, N is a batch size, C denotes a number of channels, H is a height of input planes in pixels, and W is width in pixels.

池化层

- 池化（Pooling）
  - 卷积得到的“特征图”可能包含许多冗余信息
  - 池化本质是降采样
    - 减少特征图大小
    - 保留最重要的特征
  - 常见的池化操作：
    - max pooling
    - average pooling
  - 关键参数
    - kernel_size
    - stride, padding

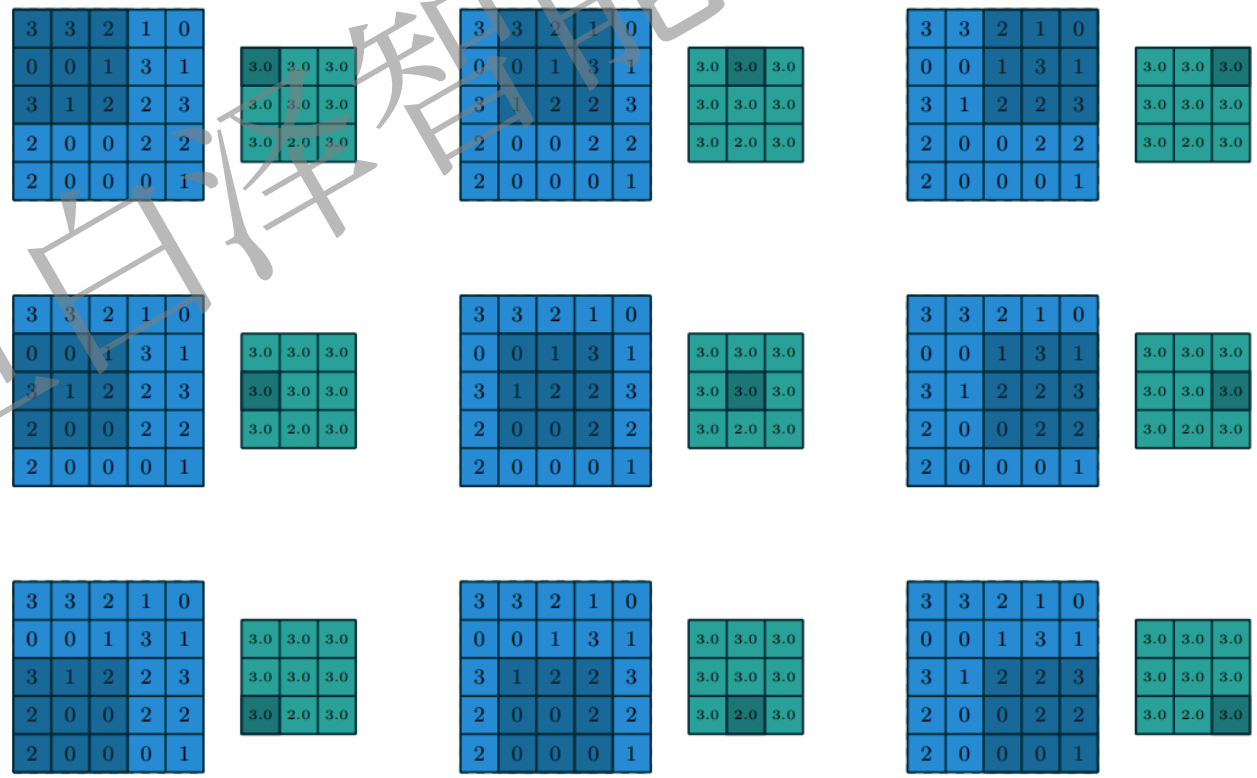

kernel_size = 3

ReLU激活函数

- 如果没有激活函数?
  - $f(\boldsymbol{x}) = \boldsymbol{W}_3(\boldsymbol{W}_2(\boldsymbol{W}_1\boldsymbol{x} + \boldsymbol{b}_1) + \boldsymbol{b}_2) + \boldsymbol{b}_3 = \boldsymbol{W}_*\boldsymbol{x} + \boldsymbol{b}_*$
- 激活函数：非线性的形式，给神经网络增加表达能力
- 我们之前学习过的sigmoid激活函数
  - 公式： $\sigma(h) = \frac{1}{1 + e^{-h}}$
  - 计算复杂，且正负饱和区存在梯度消失的风险

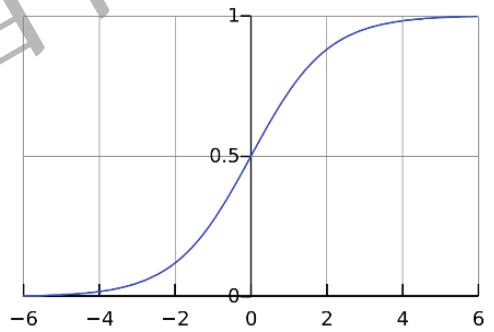

- CNN中更为常用的是ReLU激活函数
  - 公式： $\mathrm{ReLU}(x) = (x)^+ = \max(0, x)$

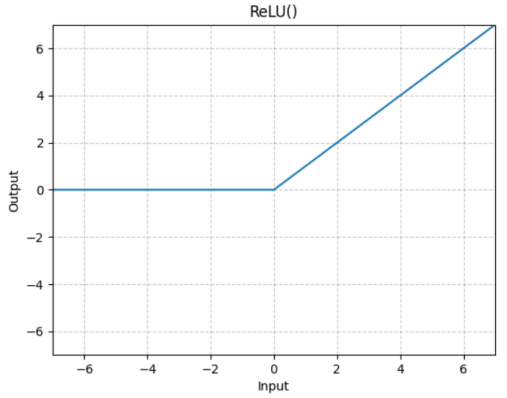

Q&A

对抗样本

x δ $x+\delta$

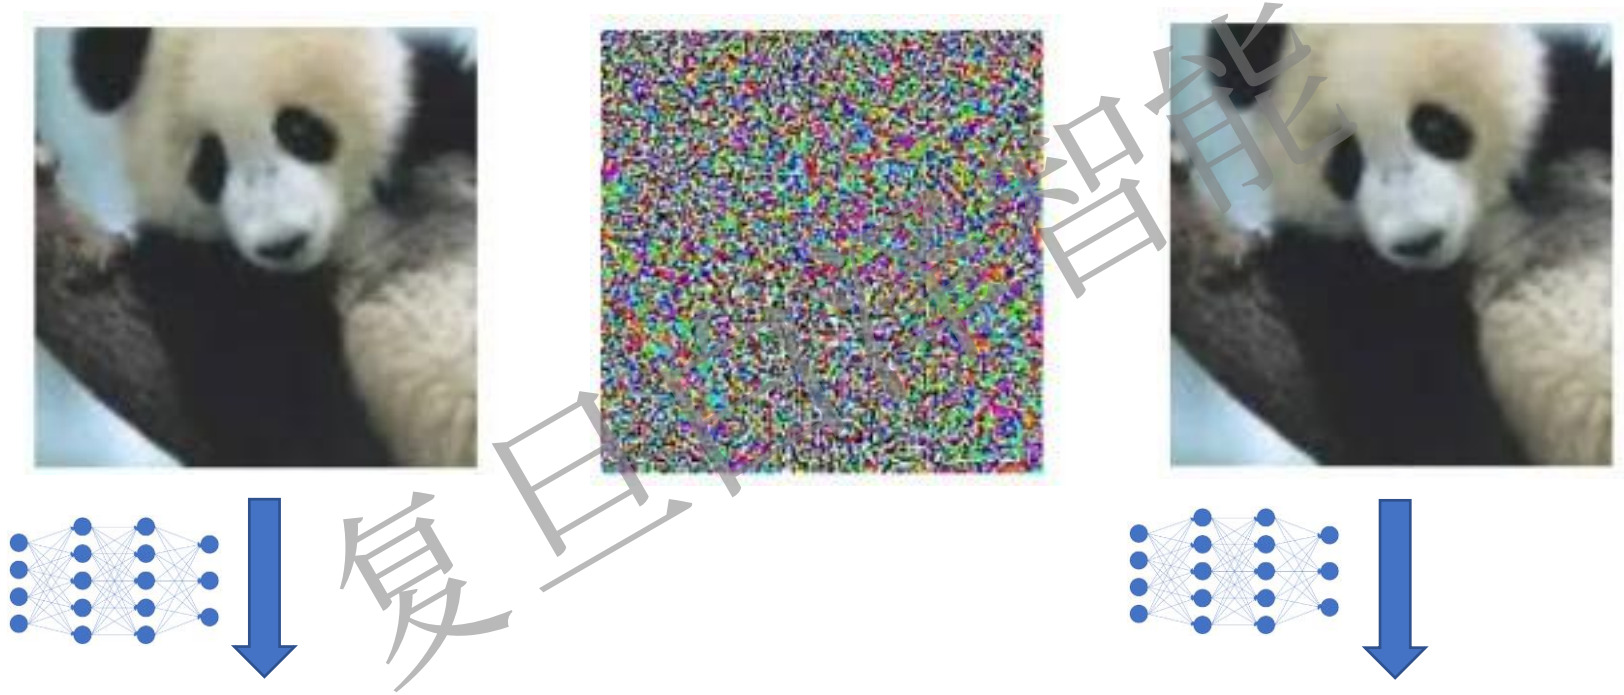

分类：大熊猫

分类：长臂猿

- 如何实现上述攻击?

回顾：最小化分类损失

- 回忆模型学习目标：
- $\min_{\theta} \ell(f_\theta(x), y)$
- 给定数据点的情况下，通过改变θ，最小化损失函数
- 目标：让模型的分类更加准确

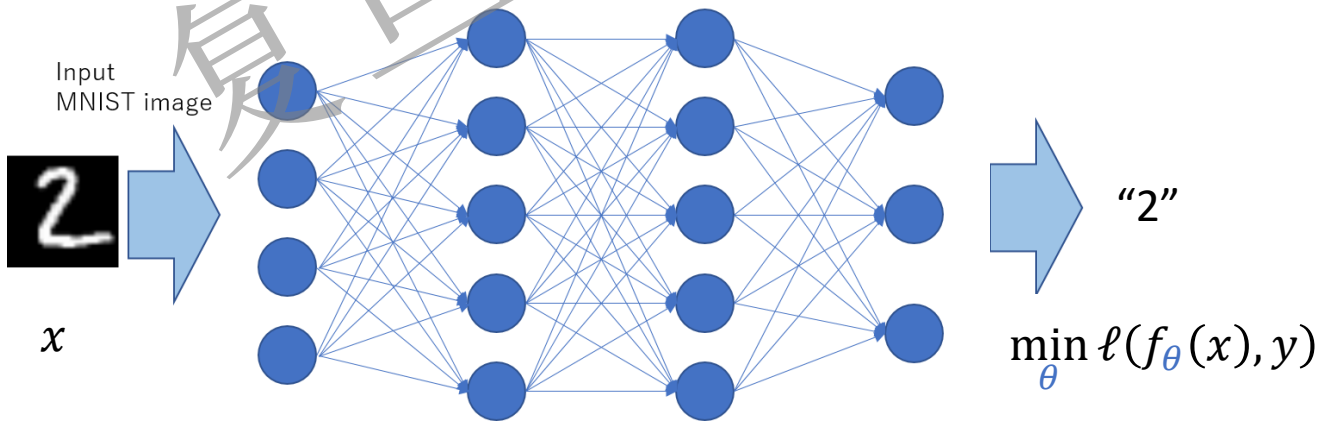

对抗样本：最大化分类损失

- 对抗样本攻击目标：
- $$\max_{\delta} \ell(f_\theta(x+\delta), y)$$
- 给定数据点和模型的情况下，通过改变δ，最大化损失函数
- 目标：让模型的分类出错

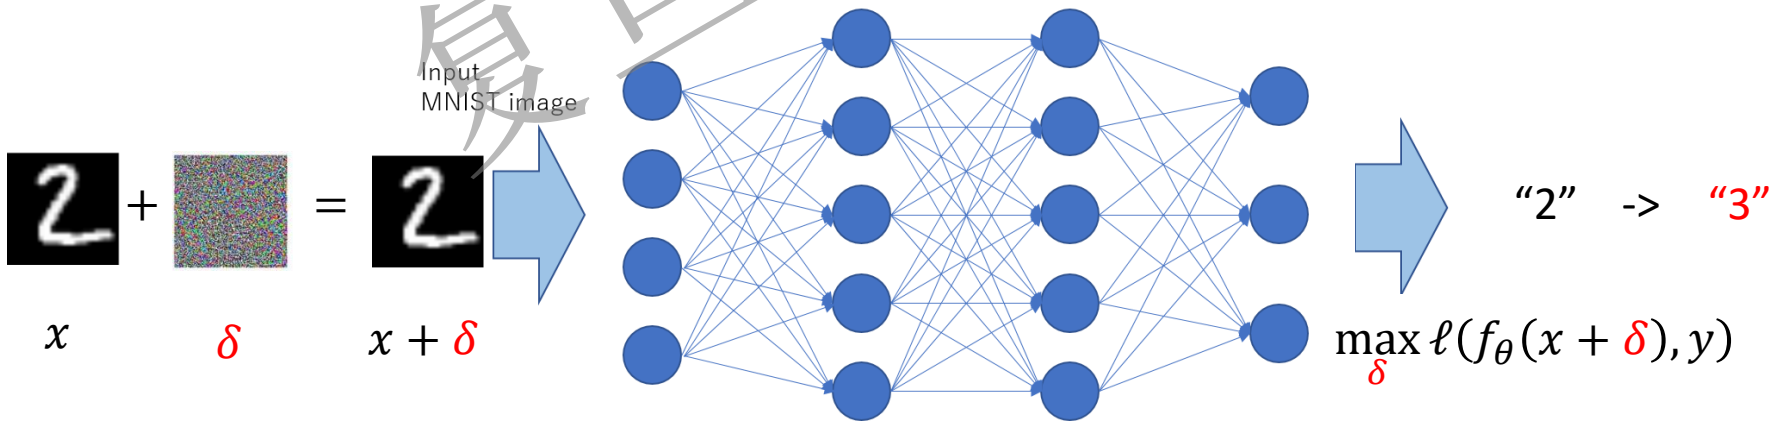

对抗样本：不可见扰动

- 如果对δ没有限制，加扰动的图片可能非常离谱

- 解决方案：
- $$\max_{\delta} \ell(f_\theta(x+\delta), y), \quad \text{s.t.} \quad \|\delta\|_\infty \leq \epsilon$$
- 每个维度扰动绝对值都小于ϵ

对抗样本：问题建模

- 对抗样本攻击目标：
- $$\max_{\delta} \ell(f_\theta(x+\delta), y), \quad \text{s.t.} \quad \|\delta\|_\infty \leq \epsilon$$
- 如何完成上述优化？

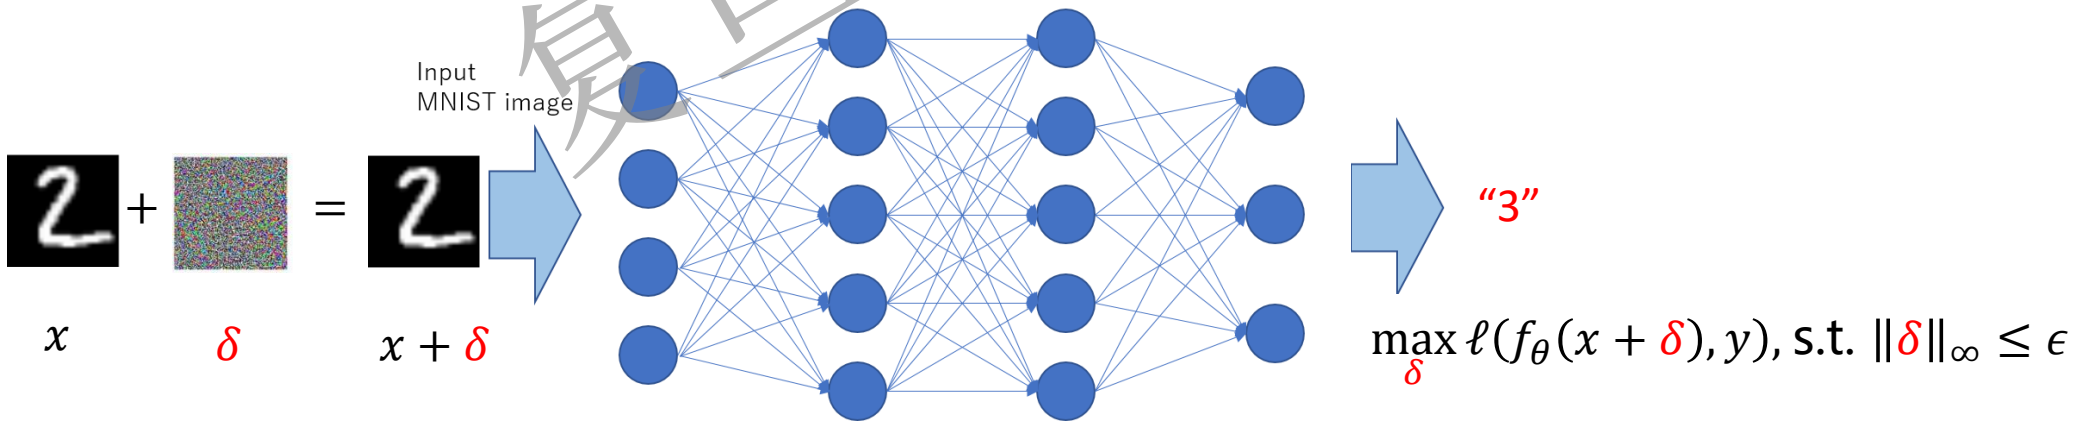

回顾：最小化分类损失的解法

- 回忆梯度下降算法：
- $\min_{\theta} \ell(f_\theta(x), y)$
- 通过一步迭代：
- $\theta = \theta - \alpha \cdot \nabla_\theta \ell(f_\theta(x), y)$
- 可以离最优解越来越近，即最小化损失函数

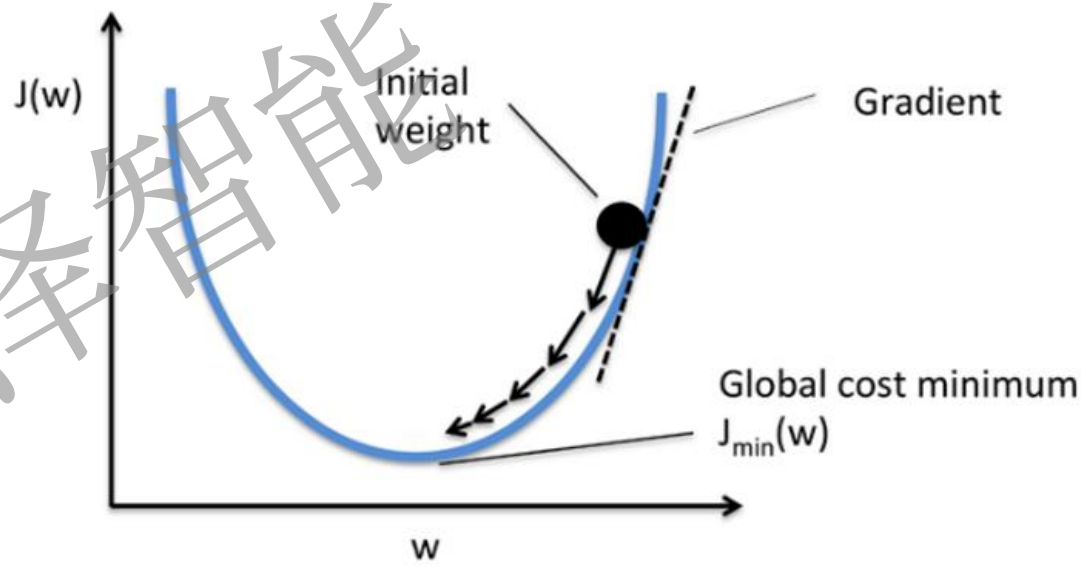

对抗样本：扰动的优化

- 如果做反向的更新：
- $\theta = \theta + \alpha \cdot \nabla_\theta \ell(f_\theta(x), y)$
- 会离最优解越来越近
- 等同于在最大化损失函数
- $\max_\theta \ell(f_\theta(x), y)$

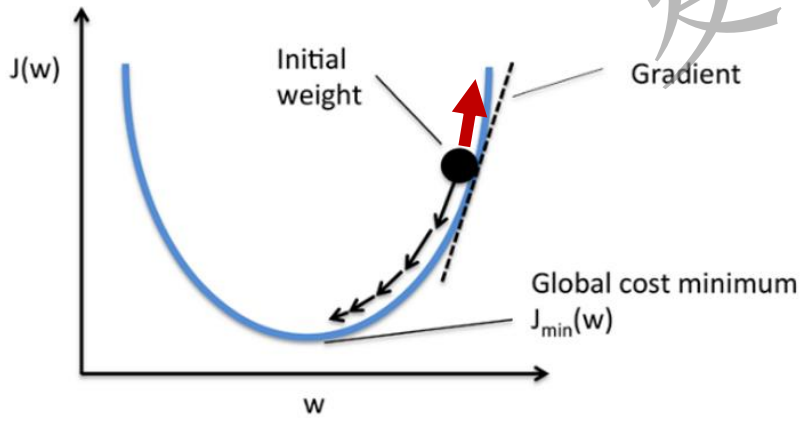

$\max_\delta \ell(f_\theta(x+\delta), y), \quad \text{s.t.} \quad \|\delta\|_\infty \leq \epsilon$

- 那如果把更新做到输入上呢？
- $\tilde{x} = x + \alpha \cdot \nabla_x \ell(f_\theta(x), y)$
- 就等同于在优化：
- $\max_x \ell(f_\theta(x), y)$

即可得到$\delta = \alpha \cdot \nabla_x \ell(f_\theta(x), y)$
下一步是如何让$\|\delta\|_\infty \leq \epsilon$

对抗样本：FGSM

- 对抗样本攻击目标：
- $\max_{\delta} \ell(f_\theta(x+\delta), y)$, s.t. $\|\delta\|_\infty \leq \epsilon$
- 对抗样本生成过程：
- $\delta = \epsilon \cdot \text{sign}\left(\nabla_x \ell(f_\theta(x), y)\right)$
- $$\text{sign}(\delta_i) = \begin{cases} +1, & \delta_i \geq 0 \\ -1, & \delta_i \leq 0 \end{cases}$$

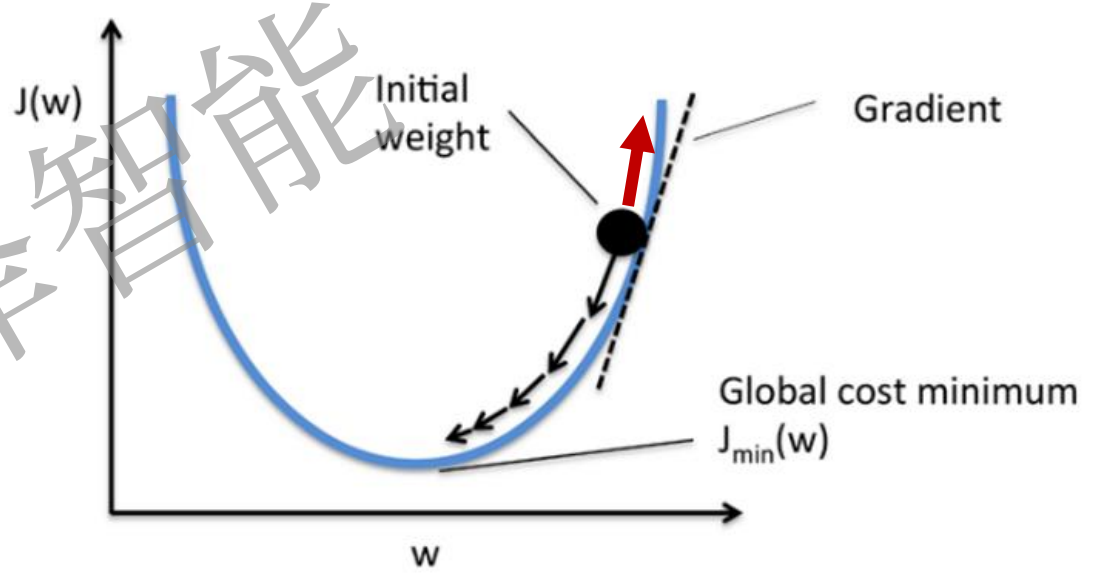

核心思想：

- 通过固定参数θ，对x做一步**反向**梯度下降，最大化损失函数
- 通过sign函数来满足对δ的约束

对抗样本：FGSM攻击流程

- 给定一个训练好的模型f_θ
- 对于给定的样本x以及对应的标签y，生成对抗样本：
- $$\tilde{x} = x + \epsilon \cdot \text{sign}\left(\nabla_x \ell(f_\theta(x), y)\right)$$
- 输入进模型，验证$f_\theta(\tilde{x})$的预测结果

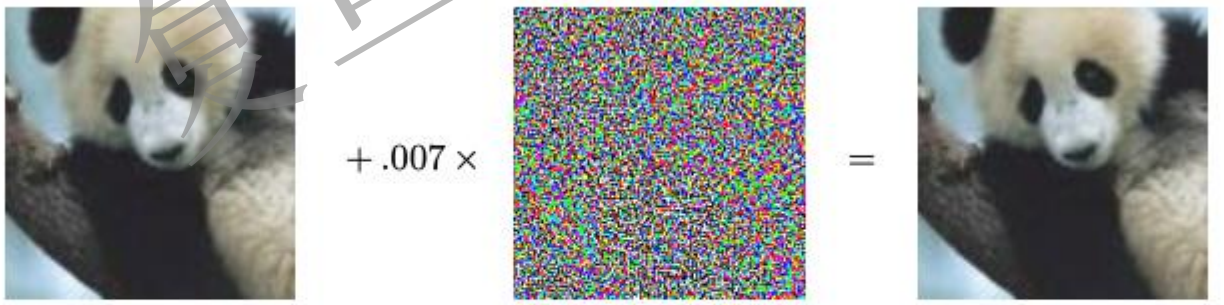

$\boldsymbol{x}$
"panda"
57.7% confidence

$\text{sign}(\nabla_{\boldsymbol{x}} J(\boldsymbol{\theta}, \boldsymbol{x}, y))$
"nematode"
8.2% confidence

$\boldsymbol{x} + \epsilon\text{sign}(\nabla_{\boldsymbol{x}} J(\boldsymbol{\theta}, \boldsymbol{x}, y))$
"gibbon"
99.3 % confidence

Q&A

实验部分

CNN与对抗样本

任务1：实现卷积神经网络LeNet5

- 上一周我们在MNIST上实现了MLP
- 本周请在MNIST上实现LeNet5
  - 完成模型结构的定义
  - 完成模型的前向传播过程
- 尽可能按下图复现
  - 基于PyTorch内置模块

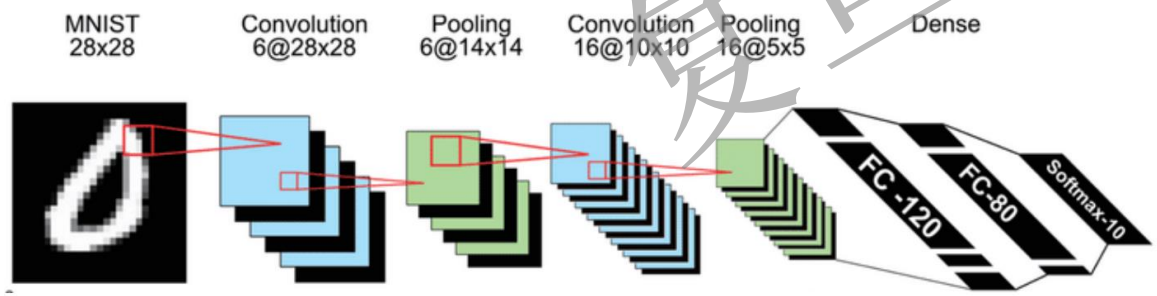


```python
##### Model Definition #####
# TODO: Week 5, Task 1
class LeNet5(nn.Module):
    def __init__(self):
        super(LeNet5, self).__init__()
        # TODO: 在这里定义模型的结构。主要依赖于nn.Conv2d和nn.Linear

    def forward(self, x):
        # TODO: 在这里定义前向传播过程。这里输入的x形状是[Batch, 1, 28, 28]

        return o
```

任务2：实现FGSM对抗攻击

- 针对你训练好的LeNet5模型进行对抗攻击
  - 完成FGSM算法的实现

$$\tilde{x} = x + \epsilon \cdot \text{sign}\left(\nabla_x \ell(f_\theta(x), y)\right)$$

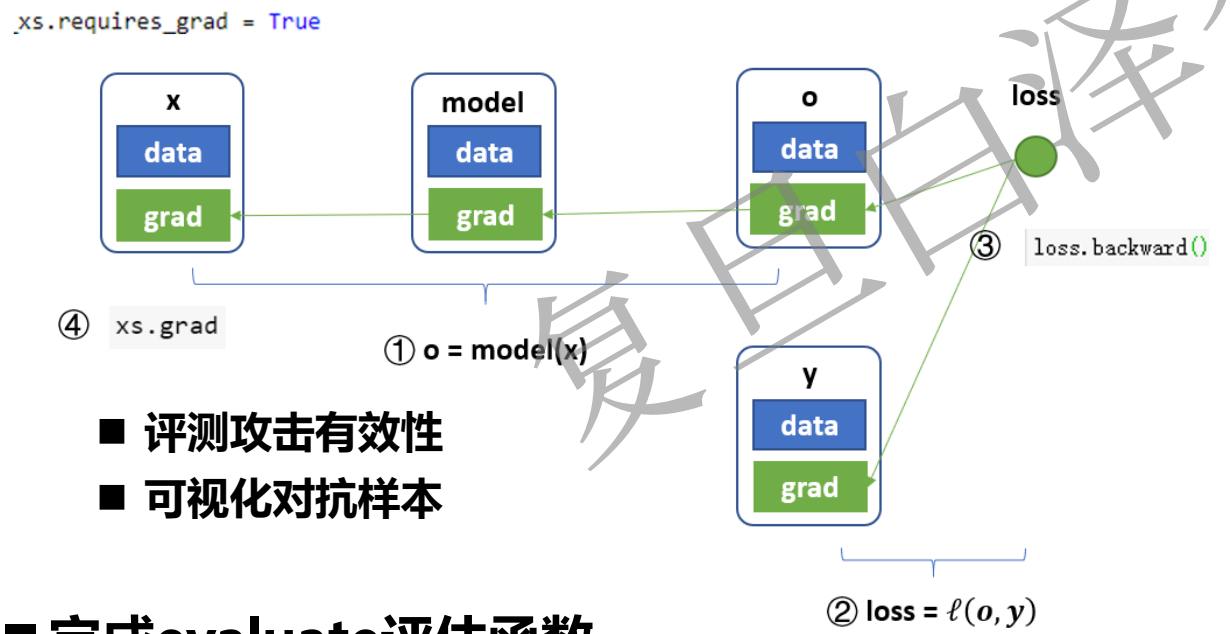

  - 评测攻击有效性
  - 可视化对抗样本
  - 完成evaluate评估函数

```python
##### Adversarial Attacks #####
# TODO: Week 5, Task 2
def fgsm(imgs, epsilon, model, criterion, labels):
    model.eval()

    adv_xs = imgs.float()
    adv_xs.requires_grad = True

    # TODO: 模型前向传播，计算loss，然后loss反传

    # TODO: 得到输入的梯度、生成对抗样本

    # TODO: 对扰动做截断，保证对抗样本的像素值在合理域内

    model.train()

    return adv_xs.detach()
```

Bonus： 实现生成对抗网络GAN

- 在MNIST上实现GAN
  - 定义Generator、Discriminator的结构与前向传播行为
  - 制定两者的训练目标，并完成训练

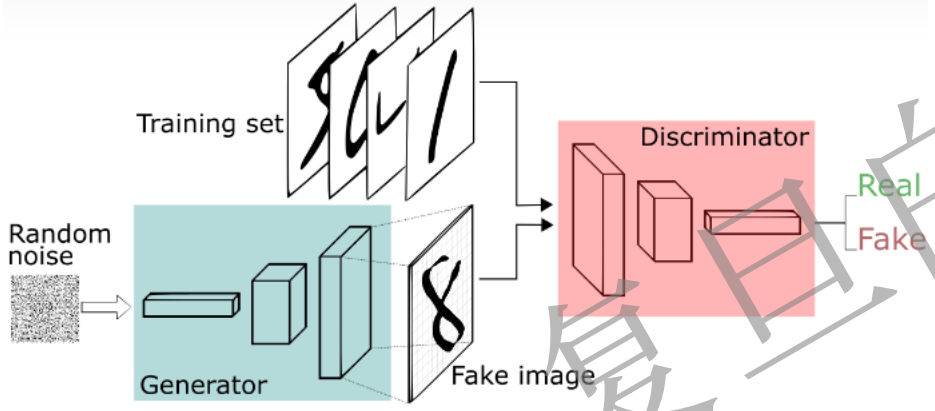

$$\min_G \max_D V(D,G) = \mathop{\mathbb{E}}_{\boldsymbol{x}\sim p_{data}(\boldsymbol{x})}\big[\log D(\boldsymbol{x})\big] + \mathop{\mathbb{E}}_{\boldsymbol{z}\sim p_{\boldsymbol{z}}(\boldsymbol{z})}\big[\log(1-D(G(\boldsymbol{z}))\big]$$

助教训了30个epoch后的生成图片：

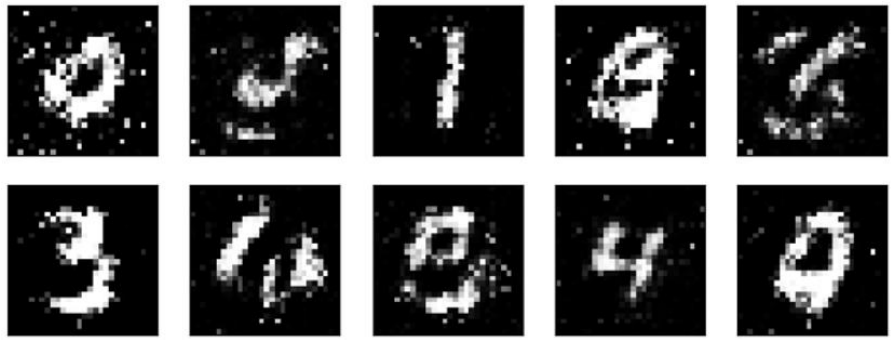

- 自主学习相关材料，要求深刻理解！！

Q&A